TODO MODELO ES UN VOTO PONDERADO

¿Quién decide la probabilidad de mora de un cliente? Otros clientes. ¿Cuántos, con qué peso y qué tanto confiar?

Grupo Taiwan · Sofía Sandoval · Herman Echeverría · Jorge Ferguson · José Gregorio Coronel

Análisis y Ciencia de Datos · UNIS · noviembre 2026

Pesos → Evidencia → Flexibilidad → Escala → Veredicto

LA IDEA Y LOS DATOS

TAIWAN CREDIT · YEH Y LIEN (2009)

30 000

clientes de tarjeta de crédito, 23 variables; y = 1 si cae en mora el mes siguiente.

Partición 80/20 (random_state = 0): 24 000 de entrenamiento y 6 000 de prueba. Mora: 22.3 % y 21.6 %.

$$\hat{y}(x) = \Sigma_i \, w_i(x) \cdot y_i$$

OLS · Ridge

Votan los 24 000, con pesos negativos.

k-NN

Votan los k más cercanos, 1/k cada uno.

Árbol · Bosque

Votan los de la misma hoja.

i **Cinco modelos, cinco maneras de decidir quién se parece a quién.** Esa noción de parecido es el **kernel**, y define la geometría del modelo.

PREPARACIÓN

0.1 · ESTANDARIZACIÓN

El `StandardScaler` se ajusta **solo con el entrenamiento** y transforma ambos. Entrenamiento: media 0 y DE 1; prueba: DE promedio 1.0098 (no se filtra información).

0.4 · DESVIACIONES ANTES DE ESTANDARIZAR

Montos (**LIMIT_BAL**, BILL_AMT, PAY_AMT): DE de **15 000 a 130 000**. Atrasos PAY_0–PAY_6, SEX, EDUCATION, MARRIAGE y edad: DE de **0.5 a 9**.

HIPERPARÁMETROS · VALIDACIÓN CRUZADA DE 5 PLIEGUES

λ ≈ 316	k = 50	prof. 4	hoja ≥ 50
ridge	k-NN	árbol	bosque

Todos más regularizados que los de la Parte 1: la y es 0/1 y muy ruidosa. Se guardan en `hiperparametros.json` y todos los notebooks los leen de ahí.

! En escala cruda cualquier distancia la deciden los montos. **Lo retomamos en la Parte 4.**

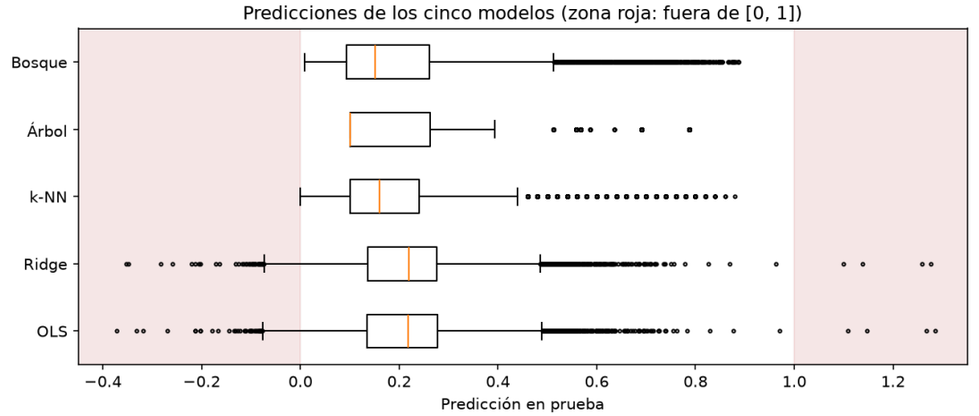
¿ES UNA PROBABILIDAD?

0.2 · Con y ∈ {0, 1}

$\hat{y}(x) = \Sigma_{i:\, y_i=1}\, w_i(x)$: el peso total de los clientes que cayeron en mora. Si $\mathbf{w_i \geq 0}$ **y** $\mathbf{\Sigma w_i = 1}$, es una combinación convexa de ceros y unos: queda en [0, 1].

	mín.	máx.	fuera de [0,1]
OLS	−0.372	1.286	436
Ridge	−0.352	1.276	430
k-NN · Árbol · Bosque	≥ 0	≤ 0.887	**0**

Predicciones en prueba (zona roja: fuera de [0, 1])



✓ OLS y ridge suman 1, pero ≈ **9 000 de sus 24 000 pesos son negativos**.

LOS PESOS DE OLS

$$w(x)^\top = \tilde{x}^\top \, (\tilde{X}^\top \tilde{X})^{-1} \, \tilde{X}^\top$$

1

Predicción

$\hat{y}(x) = \tilde{x}^\top \hat{\beta}$ y $\hat{\beta} = (\tilde{X}^\top \tilde{X})^{-1} \tilde{X}^\top y$: lo que multiplica a y es w(x).

2

Suma 1

$\mathbf{1} = \tilde{X} e_1$, así que $w(x)^\top \mathbf{1} = \tilde{x}^\top e_1 = 1$.

3

Pista: H1 = 1

H proyecta sobre las columnas de $\tilde{X}$ y el vector de unos ya está ahí.

California: Wy reproduce el .predict() con error ≈ 10^{-15}; 16 512 pesos, ≈ 5 160 negativos.

RIDGE: EL INTERCEPTO LIBRE

$$w(x)^\top = \tfrac{1}{n}\,\mathbf{1}^\top + (x - \bar{x})^\top (X_c{}^\top X_c + \lambda I)^{-1} X_c{}^\top$$

1.2 · scikit-learn no penaliza β_0

Derivando: $\hat{\beta}_0 = \bar{y} - \bar{x}^\top \beta$. Queda un ridge sobre X_c, y como $X_c{}^\top \mathbf{1} = 0$ el segundo término suma 0: **los pesos suman 1**.

✓ $\lambda = 100$ en California: cuadra con el .predict() (error $\approx 10^{-16}$).

LA VERSIÓN “OBVIA”: PENALIZAR LA COLUMNA DE UNOS

0.99398

suman ahora los pesos: n / (n + λ) = 16 512 / 16 612

No cuadra: todas las predicciones se mueven la misma constante $\lambda/(n+\lambda)\cdot\bar{y} = 0.0125$ (≈ $1 250). El intercepto se encoge hacia 0 y el modelo depende de dónde está el origen de y.

K-NN Y ÁRBOL

1.3 · k-NN (k = 30)

$$w_i(x) = \mathbf{1}\{x_i \in N_k(x)\} \,/\, k$$

Cada vecino pesa 1/30 y el resto 0. Los vecinos salen de `.kneighbors()`.

1.3 · ÁRBOL (PROFUNDIDAD 6)

$$w_i(x) = \mathbf{1}\{x_i \in L(x)\} \,/\, |L(x)|$$

Votan todas las filas de la hoja de x, con el mismo peso. La hoja sale de `.apply()`.

LO QUE TIENEN EN COMÚN

$w \geq 0, \Sigma w = 1$

Siempre dan una probabilidad.

En las 20 filas: k-NN usa 30 pesos y el árbol 535 en promedio. OLS y ridge, 16 512.

EL BOSQUE TAMBIÉN VOTA

$$w_i(x) = \tfrac{1}{T} \sum_t \mathbf{1}\{x_i \text{ en la hoja de } x \text{ en el árbol } t\} \,/\, |\text{hoja}|$$

1.4 · bootstrap = False

Cada árbol es un promedio de su hoja con **todas** las filas; el bosque promedia T árboles. Intercambiando las sumas sale la fórmula: un promedio de pesos de árbol, ≥ 0 y que suma 1.

✓ California, 200 árboles: error 2.7×10^{-15}.

CON BOOTSTRAP = TRUE

0.044

de error máximo (≈ $4 400) con la misma fórmula

Cada árbol promedia su **muestra bootstrap**: ≈ 36.8 % (e^{-1}) de las filas no aparece y otras se repiten. Contando las repeticiones c_{ti}, el error vuelve a 10^{-15}.

VERIFICACIÓN Y PROXIMIDAD

1.5 · FILA DE PRUEBA 7 (CALIFORNIA); LAS 20 FILAS PASAN EL ASSERT < 10^{-8}

	Predicción	Σ w	w ≠ 0	w < 0
OLS	3.057	1	16 512	4 144
Ridge (λ = 100)	3.056	1	16 512	4 130
k-NN (k = 30)	3.208	1	30	0
Árbol (prof. 6)	3.699	1	328	0
Bosque	3.718	1	388	0

1.6 · PROXIMIDAD DE LA FILA 7

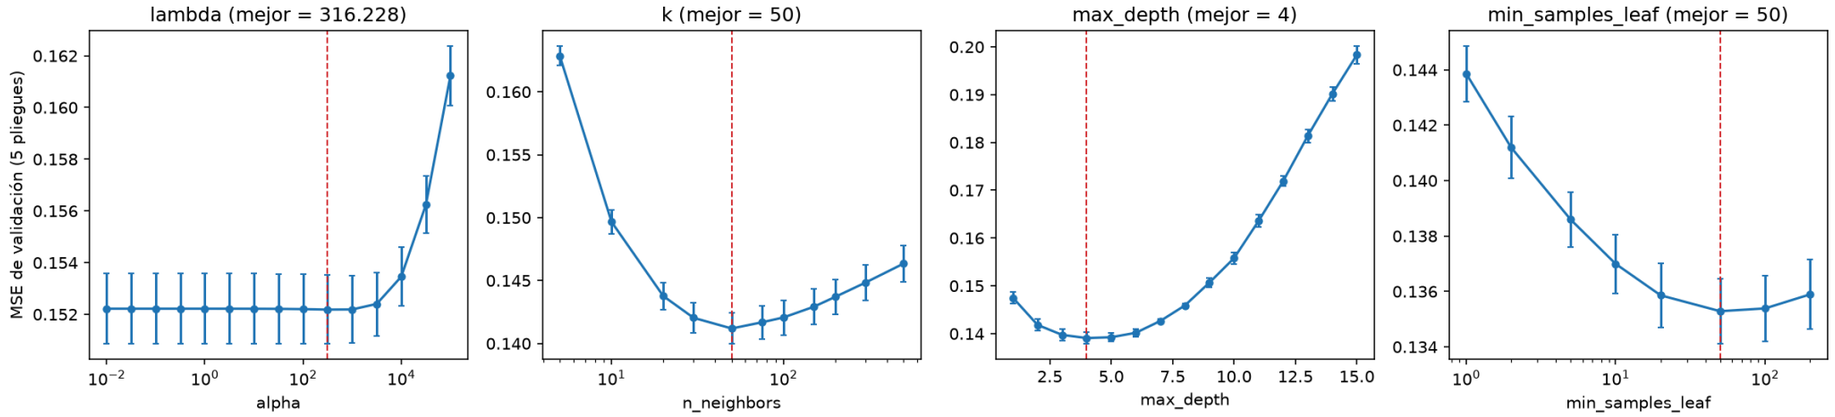
6.495

suma la proximidad: el tamaño promedio de las hojas de x

No es un peso: le falta **dividir entre el tamaño de la hoja dentro de cada árbol** antes de promediar. Marca a las mismas 388 filas.

VALIDACIÓN CRUZADA

MSE de validación (5 pliegues) para cada familia; la línea roja es el valor escogido



Ridge

Curva plana hasta λ ≈ 1 000: casi igual a OLS.

k-NN

U clara: k chico = varianza, k grande = sesgo.

Árbol

Mínimo en 4; más profundo memoriza el ruido.

Bosque

Mejora hasta hojas de 20 y luego es plano.

¿EN CUÁNTOS SE APOYA?

$$N_{ef} = (\Sigma w)^2 / \Sigma w^2 \quad \cdot \quad c = \max w^2 / \Sigma w^2$$

2.1 · N_{ef} DEL BOSQUE EN LAS 6 000 FILAS

128 – 2 371

mediana 752; c(x) máximo 0.16

Con hojas de 50, ninguna predicción depende de un puñado de clientes.

LAS TRES CONSULTAS

Consulta	y real	Bosque	N_{ef}	Desacuerdo
N_{ef} mediano (591)	0	0.057	752	0.18
N_{ef} mínimo (11705)	0	0.770	128	0.27
Mayor desacuerdo (13712)	1	0.601	181	0.75

? La tercera: donde los cinco modelos más difieren. Si la geometría cambia tanto la respuesta, el dato no la decide solo.

LOS TESTIGOS

CONSULTA MEDIANA (591)

Paga a tiempo, límite 160 000, 34 años.

k-NN y bosque: 6 %. Sus testigos también pagan a tiempo, con límites de 130 000 a 190 000.

MISMO CLIENTE EN OLS

Predice 24 %. Su testigo principal tiene **peso negativo**: límite de 340 000 y un pago de 873 552. No se le parece.

Árbol: N_{ef} = 11 767, casi todos los que pagan a tiempo.

N_{ef} MÍNIMO (11705)

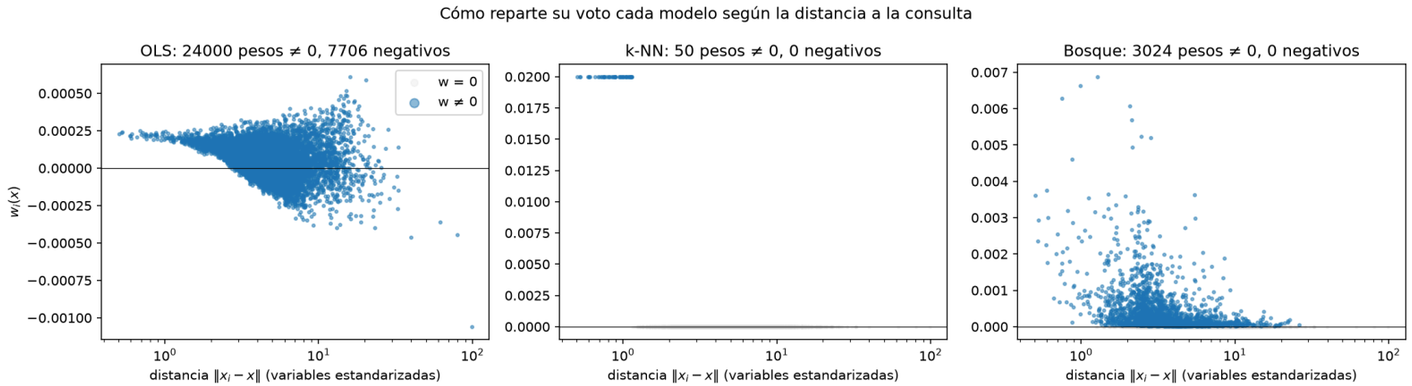
5 de 5

testigos casi copias (atraso 2–3 meses, límite 10–30 mil) cayeron en mora: el bosque dice 77 %.

Este cliente **no** cayó en mora. Poca evidencia y perfil raro: justo el caso para desconfiar.

LOS PESOS NEGATIVOS DE OLS

2.2 · $w_i(x)$ contra la distancia de x_i a x (consulta mediana): OLS, k-NN y bosque



PESOS NEGATIVOS DE OLS

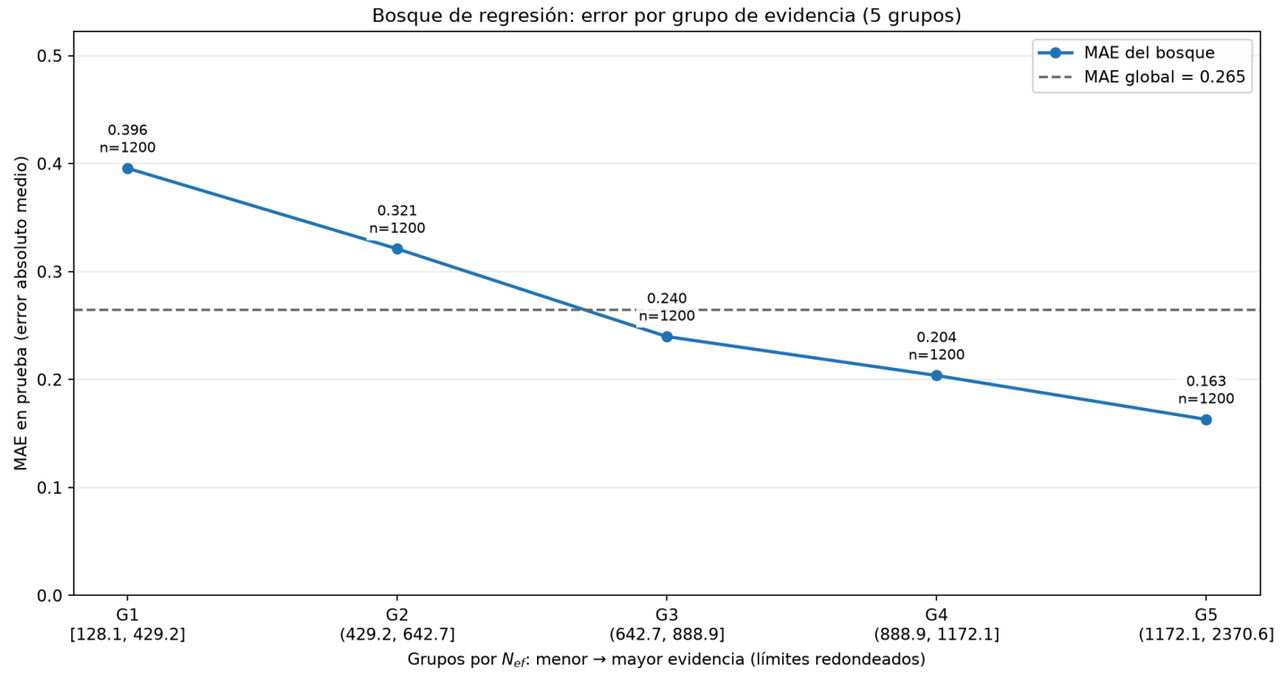
32 % · 40 % · 50 %

mediana · mínimo · desacuerdo

Los 20 más negativos están **más lejos que el 99 %** del entrenamiento. El peso $\tilde{x}^\top(\tilde{X}^\top\tilde{X})^{-1}\tilde{x}_i$ es lineal en x_i: no decae con la distancia, crece con el apalancamiento.

¿SIRVE N_{ef} PARA ALGO?

2.3 · Error absoluto medio por quintil de N_{ef} del bosque



MENOS EVIDENCIA → MÁS ERROR

0.396 → 0.163

MAE del quintil más bajo al más alto; baja en los cinco.

Pero no es causal

Los de poca evidencia también son los de más riesgo: **42.6 %** de mora contra **8.6 %**, y con y 0/1 eso solo ya sube el MAE.

¿CUÁNDO NO CONFIAR?

1

Poco respaldo

N_{ef} bajo comparado con otros casos del mismo bosque.

2

Peso concentrado

c(x) alta: unos pocos testigos mandan.

3

Testigos raros

No se parecen en lo que pesa: los meses de atraso.

4

Desacuerdo

Los modelos difieren (hasta 0.75).

! **Cifras de OLS o ridge fuera de [0, 1]** (436 filas) no se presentan como probabilidades. Y mucha evidencia puede ser poco específica (la hoja de 11 767 del árbol).

N_{ef} no es un intervalo de confianza: es una señal para revisar, no un umbral universal.

GRADOS DE LIBERTAD: tr(S)

3.1 · FÓRMULA CONTRA NP.TRACE(S) EN 2 000 FILAS

Modelo	Fórmula	tr(S)
OLS	p + 1	**24**
Ridge (λ ≈ 316)	$1 + \Sigma\, d^2/(d^2+\lambda)$	**16.54**
k-NN (k = 50)	n / k	**40**
Árbol (prof. 4)	n.º de hojas	**16**
Bosque	$\Sigma\, S_{ii}$ directo	**29.74**

S_{ii}: el peso que la fila se da a sí misma

k-NN: cada fila es su propio vecino (sin filas repetidas) → 1/k.
Árbol: cada hoja aporta $n_L \cdot (1/n_L) = 1$.

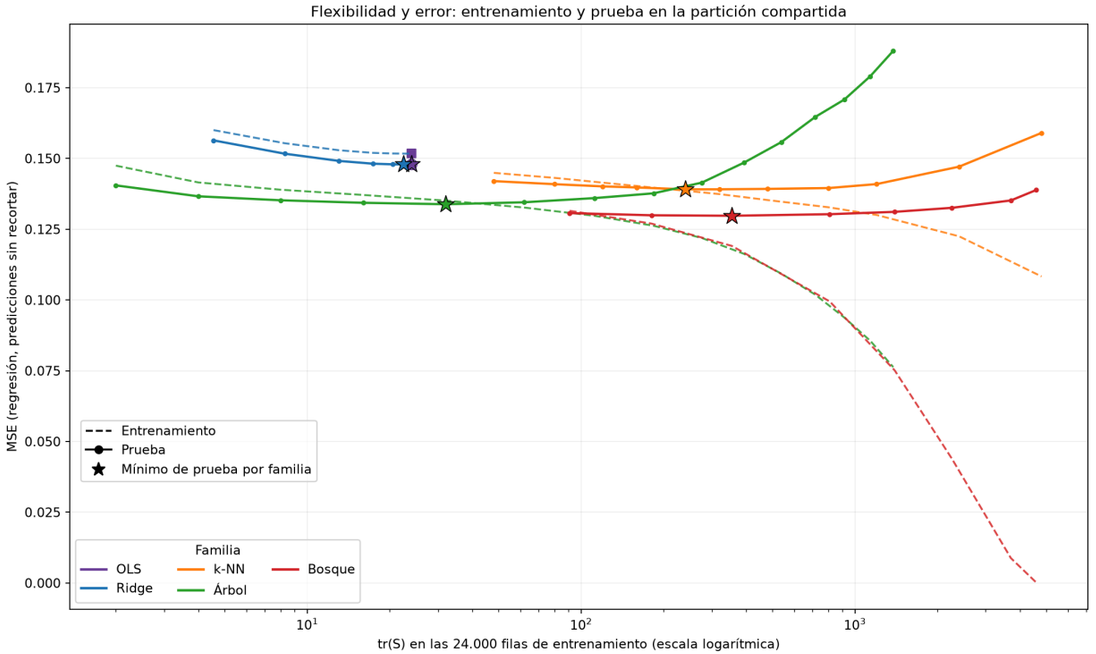
VERIFICACIÓN

diferencia ≤ 7×10^{-15}

en las cinco familias

EL PRECIO DE LA FLEXIBILIDAD

3.2 · MSE de entrenamiento y de prueba contra tr(S), cinco familias




```
Mínimos descriptivos (parámetro; traza; MSE de prueba):
OLS: sin barrido; 24.000; 0.147914
Ridge: alpha=316.228; 22.417; 0.147906
k-NN: n_neighbors=100; 240.000; 0.139091
Árbol: max_depth=5; 32.000; 0.133837
Bosque: min_samples_leaf=50; 355.235; 0.129757
```

Mínimo de prueba	tr(S)	MSE
Bosque (hoja 50)	355	**0.1298**
Árbol (prof. 5)	32	0.1338
k-NN (k = 100)	240	0.1391
Ridge / OLS	22–24	0.1479

El entrenamiento siempre baja con la traza; la prueba hace una U. Bosque con hojas de 1: **0.0002** en entrenamiento y **0.139** en prueba.

EL OPTIMISMO

$$\text{Optimismo} = \tfrac{2}{n} \sum \text{Cov}(\hat{y}_i, y_i) = 2\sigma^2 \, \text{tr}(S) / n$$

1

Definición

Error con y nuevas en los mismos x menos el de entrenamiento.

2

Expandir

Se cancelan $\hat{y}^2$ e y^2; queda $2\{E[y\hat{y}] - E[y^*\hat{y}]\} = 2\,\text{Cov}(\hat{y}_i, y_i)$.

3

S fija

$\text{Cov}(\Sigma_j S_{ij} y_j, y_i) = S_{ii}\sigma^2$.

4

Sumar

$\tfrac{2}{n} \Sigma\, S_{ii}\sigma^2 = 2\sigma^2\, \text{tr}(S)/n$.

El paso 3 necesita que S no dependa de y. No hace falta normalidad.

¿CUADRA LA FÓRMULA?

3.4 · 50 RÉPLICAS, 3 000 FILAS, σ = 0.371 (RMSE OUT-OF-BAG)

Modelo	Simulado	$2\sigma^2 tr(S)/n$	Razón
k-NN (k = 5)	0.0558 ± 0.0007	0.0551	**1.01**
k-NN (k = 30)	0.0099 ± 0.0006	0.0092	**1.08**
Ridge (λ ≈ 316)	0.0025 ± 0.0007	0.0016	**≈ 1 EE**
Árbol (prof. 6)	0.0299 ± 0.0007	0.0055	5.4
Árbol (prof. 10)	0.1018 ± 0.0013	0.0394	2.6

k-NN y ridge: sí

S solo depende de X, y X es la misma en las 50 réplicas.

ÁRBOLES: NO

Los cortes se escogen **mirando y**: S cambia en cada réplica (54–64 hojas con prof. 6). El árbol corta donde el ruido parece señal.

Contar hojas no cuenta la búsqueda de cortes.

BRECHA NO ES OPTIMISMO

3.5 · DATOS REALES, n = 24 000

Modelo	Prueba − entr.	Fórmula
k-NN (k = 5)	0.0507	0.0551
k-NN (k = 30)	0.0068	0.0092
Ridge	−0.0038	0.0003
Árbol (prof. 10)	0.0322	0.0045

1 · Otros x: en prueba no existe el voto propio; entran sesgo y varianza en un punto nuevo.

2 · Una sola partición: esta prueba es más fácil (predecir la media: 0.1695 contra 0.1730). Eso explica la brecha negativa de ridge.

3 · y 0/1: la varianza p(1−p) cambia con x. **4 · Árboles:** lo adaptativo de 3.4.

EL OUT-OF-BAG SE SALVA

3.6 · BOSQUE CON bootstrap Y oob_score

Hoja mín.	Entrenamiento	Out-of-bag	Prueba
1	0.0193	0.1404	0.1346
10	0.0958	0.1357	0.1305
50	0.1249	**0.1349**	**0.1299**

El OOB queda a menos de 0.006 de la prueba y ordena igual (50 < 10 < 1).

¿POR QUÉ?

$$\mathrm{Cov}(\hat{y}^{OOB}_i, y_i) = 0$$

Cada fila se predice solo con los árboles que **no la vieron**: 73.5 de 200 en promedio, al menos 47.

No necesita que S sea fija: es una validación cruzada gratis. Queda un poco arriba porque usa ≈ 74 árboles, no 200.

LA ESCALA TAMBIÉN ES GEOMETRÍA

4.1 · k-NN CON k = 10, MSE DE PRUEBA

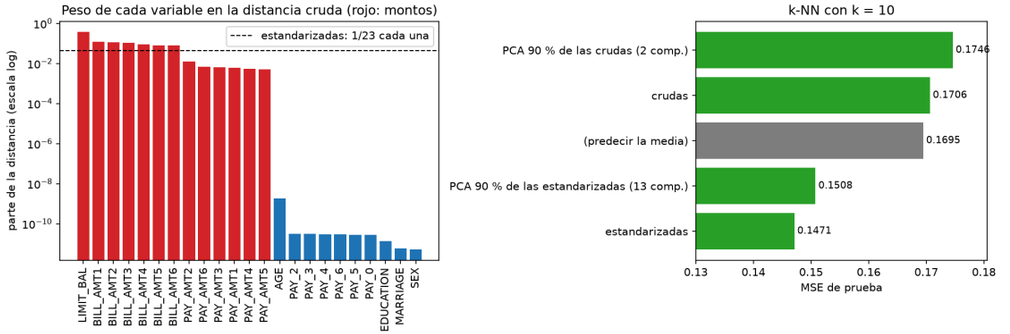
Escala	MSE
Crudas	0.1706
Estandarizadas	**0.1471**
PCA 90 % (13 comp.)	0.1508
PCA crudo (2 comp.)	0.1746
Predecir la media	0.1695

EN CRUDO, LOS MONTOS SE LLEVAN

≈ 100 % de la distancia

PAY_0–PAY_6 aportan 2×10^{-10}

Error por escala y aporte de cada variable a la distancia cruda



¿Estandarizar siempre ayuda? No. Le da el mismo peso a todas: SEX vale lo que PAY_0 y los seis BILL_AMT votan seis veces. Varianza no es relevancia.

¿LOS MISMOS VECINOS?

4.2 · CONSULTA MEDIANA (591)

0 de 10

vecinos en común entre crudo y estandarizado

En las otras dos consultas: 2 y 1.

Crudo

LIMIT_BAL 150–170 mil y BILL_AMT1 a ±5 000, pero **edades de 25 a 49**.

Estandarizado

Límite de 100 a 220 mil, pero todos de **29 a 36 años** (la consulta tiene 34).

Mora entre los vecinos	Crudo	Estandarizado	y real
Mediana (591)	0.1	0.0	0
Mayor desacuerdo (13712)	0.2	0.5	1

Mismo modelo, mismo k, otro kernel.

AL ÁRBOL NO LE IMPORTA… CASI

4.3 · En teoría

Un corte solo separa filas; estandarizar es creciente y no cambia el orden. Mismas particiones, mismos promedios.

Profundidad	Hojas	Pred. distintas
4 (la de CV)	16	**0**
10	393	1
Sin límite	3 772	8

EL CASO DE LA FILA 889

LIMIT_BAL = 170 000

Umbral: punto medio entre 160 000 y 180 000 = **170 000**. En crudo, 170 000 ≤ 170 000 → izquierda.

En estandarizado scikit-learn usa float32: el valor redondeado (0.017524086) queda dos milmillonésimas arriba del umbral (0.017524084) → derecha. Los 9 casos son empates exactos con el umbral.

K-MEANS: ¿QUIÉN SEPARA?

4.4 · k = 2

Silueta máxima en las dos escalas (0.55 crudo, 0.34 estandarizado).

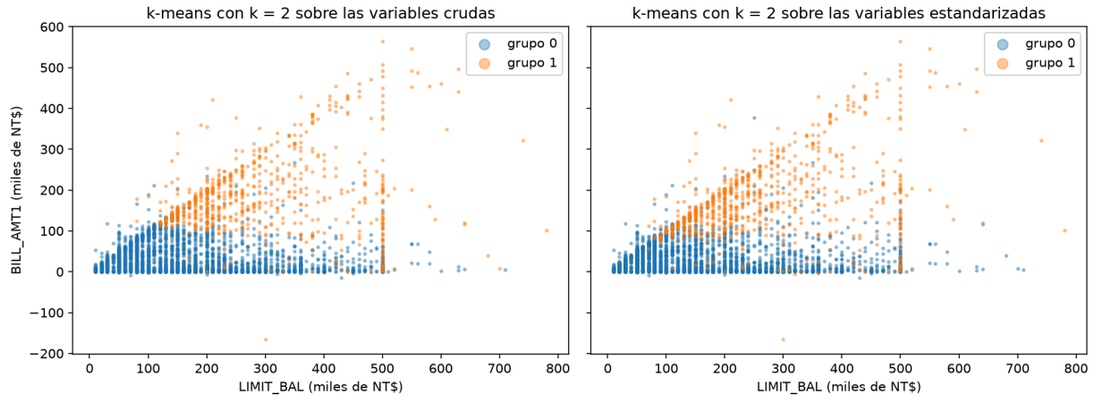
Crudo \ Est.	0	1
0	**20 093**	562
1	135	**3 210**

97 % coincide; solo 697 cambian de grupo.

LO QUE SEPARA EN CRUDO

BILL_AMT1–6

$R^2 \approx 0.59–0.61$ (LIMIT_BAL solo 0.13): seis facturas que se mueven juntas. Ninguna agrupación separa la mora (0.23 vs 0.19): k-means no mira y.



EL VEREDICTO

PARTE 5 · RECOMENDAMOS

Bosque aleatorio

MSE de prueba **0.130**

Árbol 0.134 · k-NN 0.139 · OLS y ridge 0.148 · tasa promedio 0.169

1 · **Siempre da probabilidades:** pesos ≥ 0 que suman 1.

2 · **Cada predicción tiene respaldo:** ≈ 750 clientes equivalentes y se pueden mostrar los testigos.

3 · **Se vigila sin apartar datos:** out-of-bag 0.135 contra 0.130 de prueba.

Lo que más cambia la respuesta: la escala (en k-NN), luego la flexibilidad y la partición.

CONCLUSIONES

¿Quién predice?

Otros clientes

Los cinco modelos son un voto ponderado; los pesos reproducen el .predict() a 10^{-15}.

¿Cuánto confiar?

N_{ef} + testigos

Poco respaldo, testigos raros o desacuerdo: revisar a mano.

¿Qué lo cambia?

La escala

En k-NN, crudo es peor que la tasa promedio; estandarizado baja a 0.147.

✓ Nunca evaluar con el error de entrenamiento: con árboles el optimismo es **varias veces** lo que dice la fórmula. Prueba u **out-of-bag**.

FUENTES Y LIBRERÍAS

Datos

- **Taiwan Credit** (Yeh y Lien, 2009): 30 000 clientes, 23 variables.
- **California Housing** (Pace y Barry, 1997), Parte 1.

Teoría y herramientas

- **Sudjianto**, *The Learned Kernel* (2026).
- **Hastie, Tibshirani y Friedman**, ESL §7.4 y §7.6.
- **Python:** numpy, pandas, scikit-learn, matplotlib.

Código y datos: github.com/SSIsa14/VotoPonderado_TaiwanCredit

¡GRACIAS!

¿Preguntas?

Sofía Sandoval · Herman Echeverría · Jorge Ferguson · José Gregorio Coronel